

Project Status / Estado del Proyecto

Sim-to-Real with TransformerPayne

Felix Hauger

13 July 2026

Contents

1	Estado del Proyecto / Project Status	1
1.1	1. En una frase / In one sentence	1
1.2	2. Resultado principal / Main result	1
1.3	3. La causa del problema de DESI / The cause of the DESI problem	2
1.4	4. Otros resultados / Other results	2
1.5	5. La pipeline / The pipeline	3
1.6	6. Figuras clave / Key figures	5
1.7	7. Qué falta / What is missing	5

1 Estado del Proyecto / Project Status

1.0.1 Sim-to-Real con TransformerPayne — rama de Felix / Felix's branch

Última actualización / last updated: 13-07-2026

1.1 1. En una frase / In one sentence

ES: Entrenamos un clasificador espectral **solo con espectros sintéticos** (generados con TransformerPayne) y lo probamos en espectros **reales** — y funciona: en SDSS alcanza el techo de lo que logra un modelo entrenado con datos reales etiquetados, **sin usar ni una etiqueta**.

EN: We train a spectral classifier **purely on synthetic spectra** (generated with TransformerPayne) and test it on **real** spectra — and it works: on SDSS it reaches the ceiling of what a model trained on real labelled data achieves, **without using a single label**.

1.2 2. Resultado principal / Main result

	DESI	SDSS
(1) Entrenado con sintéticos → real	0.752	0.956
(2) Entrenado con reales → real (techo)	0.843	0.940
Domain shift = (2) – (1)	+0.090	–0.017
Cross-survey: real DESI → real SDSS	—	0.828

ES — cómo leerlo: - En **SDSS el domain shift es CERO** (–0.017, dentro del error). Lo sintético **iguala** al entrenamiento con datos reales — y con 10.000 espectros de entrenamiento

en vez de 594, sin necesitar etiquetas. **Ese es el punto del proyecto, y está demostrado.**
 - En **DESI da 0.752, pero NO es culpa del método:** el techo de DESI es solo 0.843 (el de SDSS es 0.940). Ni un modelo entrenado con DESI real supera eso. - **La prueba definitiva:** un modelo entrenado con **DESI real** solo llega a **0.828 en SDSS real** — o sea, los dos instrumentos **no coinciden entre sí**, sin ninguna simulación de por medio. El problema es instrumental.

EN — how to read it: - On **SDSS the domain shift is ZERO** (-0.017 , within the error). Synthetic training **matches** training on real labelled data — with 10,000 training spectra instead of 594, and no labels. **That is the point of the project, and it is demonstrated.**
 - On **DESI it gives 0.752, but this is NOT the method's fault:** DESI's own ceiling is only 0.843 (SDSS's is 0.940). Not even a model trained on real DESI beats that. - **The decisive test:** a model trained on **real DESI** reaches only **0.828 on real SDSS** — the two instruments **disagree with each other**, with no simulation involved at all.

1.3 3. La causa del problema de DESI / The cause of the DESI problem

ES: Medimos el espectro medio de estrellas G a la **misma temperatura** en ambos surveys. Todas las líneas coinciden (razón 0.97-1.10) **excepto una:**

Línea	DESI	SDSS	razón
H-delta	0.348	0.334	1.04
Ca I	0.334	0.303	1.10
Banda G (CH)	0.385	0.396	0.97
H-gamma	0.380	0.362	1.05
H-beta	0.298	0.374	0.80

La H-beta de DESI es 20 % más plana. Y con SHAP mostramos que el Random Forest decide **casi solo con esa línea**. Una H-beta débil = Balmer débil = estrella fría = **K**. Por eso las G de DESI se clasifican como K, en todo el rango de temperatura y nunca al revés.

EN: We measured the mean spectrum of G stars at the **same temperature** in both surveys. Every line agrees (ratio 0.97-1.10) **except one: DESI's H-beta is 20 % shallower.** And SHAP showed the Random Forest decides **almost entirely with that line**. Weak H-beta = weak Balmer = cool star = **K**. Hence DESI's G stars get classified as K, at every temperature and never the other way.

Hipótesis descartadas / hypotheses ruled out (cada una probada y refutada / each tested and refuted):

Hipótesis / Hypothesis	Resultado / Result
Gigantes ($\log g < 3.5$) fuera del rango de entrenamiento	NO 0.760 $\rightarrow$ 0.770
Estrellas fuera del dominio de T_{eff}	NO 0.753
Velocidad radial sin corregir	NO desplazamiento $<$ ruido de medición
Sesgo de la normalización del continuo	NO sin sesgo azul/rojo
Enmascarar las líneas al normalizar (el "fix" de H-beta)	! arregla H-beta (0.80 $\rightarrow$ 0.94) pero empeora DESI (0.752 $\rightarrow$ 0.637)

1.4 4. Otros resultados / Other results

ES / EN:

- **Saturación / Saturation.** La accuracy real se **satura ya en ~2.000 espectros sintéticos** (2k: 0.776 · 10k: 0.752 · 100k: 0.759). Los 100k del profe no aportan nada, y **el problema de conseguir 700.000 espectros nunca fue un problema.** / Real accuracy plateaus at ~2,000 synthetic spectra. More data adds nothing.
- **Segundo emulador / Second emulator (The Payne).** Un MLP estilo Payne entrenado sobre espectros de TransformerPayne reproduce el espectro con RMSE 0.011 (por debajo del ruido, $\sigma=0.02$) y da la misma transferencia: **TransformerPayne 0.78 vs The Payne 0.77.** → **El emulador no es el cuello de botella.** / The emulator is not the bottleneck.
- **Normalización / Normalization.** Ensanchamiento $R(\lambda)$ + normalización iterativa del continuo, aplicados **igual** a sintéticos y reales, subieron DESI de **0.66 → 0.76** y arreglaron la confusión K→G (recall de K: 0.43 → 0.85). Los dos efectos son **acoplados**: por separado no sirven. / The two effects are **coupled**: neither works alone.
- **F como experimento extra / F as an extra experiment.** Con F/G/K sobre datos reales la accuracy cae de 0.843 a **0.717** y el recall de G se hunde a 0.47 — F (6000–7500 K) y G (5200–6000 K) se confunden en el borde. **Confirma que presentar G/K fue lo correcto.** / Confirms that presenting G/K was the right call.
- **Interpretabilidad del clasificador / Classifier interpretability (SHAP).** El Random Forest decide con las **líneas de Balmer**: H-beta domina (5 de las 10 longitudes de onda más importantes son píxeles de H-beta), luego H-gamma. Físicamente correcto: G vs K es un corte en temperatura, y Balmer es el termómetro. / Physically correct.
- **Interpretabilidad del EMULADOR / EMULATOR interpretability.** Medimos $\partial \text{flujo} / \partial [X/H]$ para los 10 elementos. Los que **no tienen líneas** en 4000–5000 Å (Na, S, N, K) dan sensibilidad **~cero** (0.02–0.07); los que sí tienen dominan (Fe 1.00, C, Mg, Ca, Ti, Mn) y **su máximo cae sobre sus líneas conocidas** (Ca I en 4226.7 Å, etc.). **TransformerPayne aprendió física, no correlaciones** — y es una prueba que podía fallar. / TransformerPayne learned physics, not correlations — and this was a test that could have failed.
- **La conexión entre ambas / The link between the two.** El emulador dice que Ca I y la banda G están controladas por la **abundancia** — y nosotros variamos las abundancias al azar (± 1 dex). Esas líneas son, por lo tanto, discriminadores ambiguos. Y SHAP muestra que el clasificador **las ignora** y usa Balmer, la única señal puramente térmica. **El clasificador aprendió a evitar exactamente las líneas que el emulador marca como contaminadas por abundancia.** / The classifier learned to avoid exactly the lines the emulator flags as abundance-contaminated.

1.5 5. La pipeline / The pipeline

```

00_fetch_sdss.py    -> descarga espectros reales de SDSS (SkyServer)
                    download real SDSS spectra
    |
06_generate_large.py -> genera N espectros sintéticos con TransformerPayne -> .npz
                    generate N synthetic spectra -> .npz
    |
07_train_large.py   -> entrena el RF con los sintéticos, evalúa en los reales
                    train the RF on synthetic, evaluate on real
    |
14_train_real.py    -> entrena con REALES: el techo + F/G/K + cross-survey
                    train on REAL: the ceiling + F/G/K + cross-survey
    |
15_summary.py       -> la escala de referencia (FIGURA PRINCIPAL)
                    the reference scale (MAIN FIGURE)

```

1.5.1 Scripts

Script	ES	EN
project_lib.py	librería compartida: grilla, normalización, ensanchamiento, carga	shared library: grid, normalization, broadening, loading
00_fetch_desi.py	descarga DESI (SPARCL — actualmente caído)	fetch DESI (SPARCL — currently down)
00_fetch_sdss.py	descarga SDSS vía SkyServer (funciona)	fetch SDSS via SkyServer (works)
01_generate_train.py	pipeline chica: genera, entrena, figuras del milestone	small pipeline: generate, train, milestone figures
02_evaluate_real_desi.py	accuracy real sobre espectros etiquetados	real accuracy on labelled spectra
03_broadening.py	efecto del ensanchamiento $R(\lambda)$	effect of the $R(\lambda)$ broadening
04_check_broadening.py	chequeo visual del ensanchamiento	visual check of the broadening
05_normalization.py	progreso: baseline → ensanch. → normalización → ambas	progression chart
06_generate_large.py	generación a gran escala (multiproceso, hasta 100k)	large-scale generation (multiprocessing)
07_train_large.py	RF desde el .npz + evaluación real (filtros $\log g/T_{\text{eff}}/\lambda$)	RF from .npz + real eval ($\log g/T_{\text{eff}}/\lambda$ filters)
08_shap.py	interpretabilidad del clasificador (SHAP)	classifier interpretability
09_payne_compare.py	segundo emulador (The Payne) y comparación	second emulator and comparison
10_saturation.py	curva de aprendizaje: accuracy vs nº de espectros	learning curve
11_compare_real_samples.py	poblaciones estelares DESI vs SDSS ($T_{\text{eff}}/\log g$)	stellar populations DESI vs SDSS
12_misclassified.py	¿dónde en T_{eff} están los errores?	where in T_{eff} are the errors?
13_spectra_compare.py	espectro medio DESI vs SDSS → encontró la H-beta	mean spectrum DESI vs SDSS → found the H-beta
14_train_real.py	entrenamiento con reales : techo, F/G/K, cross-survey	real training : ceiling, F/G/K, cross-survey
15_summary.py	la escala de referencia (figura principal)	the reference scale (main figure)
16_attention.py	interpretabilidad del emulador (sensibilidad por elemento)	emulator interpretability
run_all.bat	corre TODO de una / runs EVERYTHING in one go	

Cómo correr todo / How to run everything:

```
conda activate astro-jax
run_all.bat > run_all_log.txt 2>&1
```

1.6 6. Figuras clave / Key figures

Figura	ES	EN
summary_scale_GK_iterative.png	la escala de referencia — figura principal	the reference scale — main figure
spectra_compare_*.G.png	la H-beta de DESI, 20 % más plana	DESI's H-beta, 20 % shallower
emulator_sensitivity_G.png	qué elemento controla qué línea	which element controls which line
shap_importance.png	qué longitudes de onda usa el clasificador	which wavelengths the classifier uses
saturation_curve.png	la accuracy se satura en ~2.000 espectros	accuracy saturates at ~2,000 spectra
emulator_comparison.png	TransformerPayne vs The Payne	
cross_survey_*.png	DESI real → SDSS real	
real_trained_*.png	el techo / the ceiling	

1.7 7. Qué falta / What is missing

ES / EN:

1. **Decisión con Steve: “todas las clases espectrales”.** Con TransformerPayne **no es alcanzable** — solo está validado para enanas de ~4000-6000 K (G, K, y F apenas). Para O/B/A/M el emulador está fuera de su grilla. Además, por la IMF esas estrellas casi no existen (LAMOST tiene **234** estrellas O en total). Hay dos límites independientes: el **emulador** y los **datos**. / Not achievable with TransformerPayne; two independent limits: the emulator and the data.
2. **Las etiquetas Teff de DESI (MWS)** parecen menos precisas que las de SDSS (SSPP) — el techo bajo de DESI (0.843 vs 0.940) lo sugiere. Afecta a todo el equipo, no solo a esta rama. / DESI's MWS Teff labels look less precise than SDSS's SSPP. This affects the whole team.
3. **La presentación.** / The presentation.